

LocalLLM-DataForge: Un Pipeline Modular para Conjuntos de Datos Sintéticos de Descomposición de Historias de Usuario con Validación tipo LLM-as-a-Judge

Abstract

La descomposición de historias de usuario en tareas de desarrollo es una práctica habitual en los proyectos ágiles; sin embargo, continúa siendo un proceso altamente dependiente del juicio humano. Los intentos de automatizar esta actividad mediante técnicas de aprendizaje automático suelen enfrentar dos limitaciones recurrentes: la escasez de conjuntos de datos anotados y la dependencia de modelos de lenguaje basados en servicios en la nube. Este trabajo presenta *LocalLLM-DataForge*, un framework modular basado en DataFrames para la generación y evaluación de conjuntos de datos sintéticos orientados a la descomposición de historias de usuario utilizando modelos de lenguaje ejecutados localmente. El framework integra modelos generadores y evaluadores dentro de un pipeline reproducible, incorporando mecanismos de validación automática basados en el paradigma *LLM-as-a-Judge* y permitiendo la experimentación con distintas configuraciones de modelos y parámetros. La propuesta se evaluó sobre un conjunto de datos mediante múltiples configuraciones de modelos de código abierto. Los resultados muestran que es posible generar descomposiciones con niveles consistentes de calidad, observándose diferencias notables en desempeño y estabilidad dependiendo de la configuración de los modelos. En particular, se identifica un compromiso entre diversidad y consistencia asociado a parámetros como la temperatura, así como una mayor estabilidad en criterios estructurales frente a una mayor variabilidad en criterios semánticos. Estos hallazgos sugieren que los LLMs ejecutados localmente constituyen una alternativa viable para la generación de datasets sintéticos en ingeniería de requisitos, proporcionando ventajas en términos de reproducibilidad, control de datos y costo.

Keywords: Requirements engineering, Natural language processing, Large language models, Synthetic data generation, Task decomposition, Automated evaluation

1 Introducción

Las historias de usuario son uno de los artefactos de requisitos más utilizados en el desarrollo de software ágil. Los equipos suelen apoyarse en ellas para capturar necesidades funcionales desde la perspectiva del usuario final de forma concisa y accesible [1, 2]. En la práctica, su función va más allá de la comunicación: las historias de usuario se emplean de manera habitual para apoyar la planificación, la estimación de esfuerzo y las actividades cotidianas de desarrollo. En particular, la descomposición de las historias en tareas de desarrollo concretas resulta crítica durante la refinación del backlog y la planificación de sprints [3, 4]. Aun así, esta actividad sigue dependiendo en gran medida del trabajo manual y de la experiencia acumulada del equipo.

Cuando la descomposición de tareas se realiza de forma manual, tienden a aparecer una serie de problemas recurrentes. Distintos miembros del equipo pueden interpretar una misma historia de usuario de maneras ligeramente diferentes, lo que da lugar a niveles inconsistentes de granularidad y a supuestos implícitos que nunca llegan a documentarse por completo. Algunos detalles relevantes pueden pasarse por alto (e.g., restricciones funcionales implícitas), mientras que otros aspectos se descomponen en exceso. Con el tiempo, estas inconsistencias contribuyen a la creación de backlogs poco estructurados, lo que dificulta la estimación y la asignación de tareas [5]. El problema suele intensificarse en equipos grandes o distribuidos, donde la ausencia de prácticas compartidas de descomposición debilita la trazabilidad y complica la automatización sistemática de los flujos de trabajo en ingeniería de requisitos [6].

Los avances recientes en Procesamiento del Lenguaje Natural (NLP, por sus siglas en inglés), junto con la rápida evolución de los Modelos de Lenguaje Grande (LLMs, por sus siglas en inglés), han abierto nuevas posibilidades para automatizar tareas que tradicionalmente quedaban en manos de ingenieros de software [7, 8]. Trabajos previos han explorado el uso de LLM para la clasificación de requisitos, la detección de ambigüedades, la generación de casos de prueba y la derivación de tareas de desarrollo a partir de descripciones en lenguaje natural [9, 10]. Sin embargo, la mayoría de las soluciones existentes dependen de modelos propietarios alojados en la nube. Esta dependencia introduce preocupaciones prácticas relacionadas con el costo, la confidencialidad de los datos, la reproducibilidad y la disponibilidad a largo plazo, tanto en contextos de investigación como industriales.

Una limitación compartida por muchos enfoques basados en LLM es la falta de conjuntos de datos adecuados para entrenamiento y evaluación. Los datasets públicos centrados específicamente en la descomposición de historias de usuario siguen siendo escasos, en gran medida debido al elevado costo de la anotación por expertos y a la naturaleza sensible de los requisitos del mundo real [11]. La generación de datos sintéticos mediante LLM se ha propuesto como una solución parcial. No obstante, muchos de los métodos existentes ofrecen poca visibilidad sobre cómo se validan las salidas generadas. Como consecuencia, evaluar la corrección semántica, la completitud o la coherencia lógica resulta complicado [12]. Además, una generación poco controlada incrementa el riesgo de alucinaciones, lo que puede reducir la confianza en los conjuntos de datos resultantes.

Se presenta LocalLLM-DataForge, un framework modular diseñado para generar conjuntos de datos sintéticos orientados a la descomposición de historias de usuario

utilizando LLMs ejecutados de forma local. El framework se apoya en DataFrames para estructurar y gestionar los resultados intermedios del proceso de generación. Asimismo, se integra con Ollama para ejecutar modelos de lenguaje de código abierto sin depender de servicios en la nube. Uno de sus componentes centrales es un mecanismo de caché inteligente, que evita cálculos repetidos durante experimentos iterativos y contribuye a reducir los tiempos de ejecución al explorar distintas configuraciones de generación.

El control de calidad se aborda mediante mecanismos de validación automática. LocalLLM-DataForge aplica estrategias de LLM como juez para evaluar las descomposiciones de tareas generadas. Se consideran dos enfoques de evaluación, el primero se basa en un único generador y evalúa sus salidas a partir de criterios de calidad explícitos (i.e., coherencia, completitud, viabilidad, formato y granularidad) [13]. El segundo compara las salidas producidas por múltiples generadores y selecciona la descomposición más adecuada. Esta estrategia comparativa aprovecha principios de consenso que han demostrado mejorar la fiabilidad y reducir errores semánticos en las salidas de los modelos [14, 15].

Este trabajo realiza dos contribuciones principales. En primer lugar, presenta un framework completamente local, extensible y reproducible para la generación de conjuntos de datos sintéticos a partir de historias de usuario, abordando de forma explícita restricciones de costo y privacidad. En segundo lugar, define y operacionaliza estrategias automáticas de validación basadas en LLM como juez, adaptadas a artefactos de ingeniería de requisitos.

Para evaluar la viabilidad del enfoque propuesto, se realizan experimentos sobre el conjunto de datos Salony utilizando varios LLM de código abierto. Los resultados permiten analizar tanto la calidad de las descomposiciones generadas como el comportamiento de las estrategias de evaluación comparativa entre modelos.

El resto del artículo se organiza de la siguiente manera. La Sección 2 revisa el trabajo relacionado sobre automatización basada en LLM en ingeniería de requisitos y generación de datos sintéticos. La Sección 3 describe la arquitectura y los componentes principales de LocalLLM-DataForge. La Sección 4 presenta la configuración experimental y los resultados obtenidos. La Sección 5 discute los hallazgos y sus implicaciones, mientras que la Sección 6 expone las conclusiones y las líneas de trabajo futuro.

2 Trabajos Relacionados

La automatización de actividades dentro de la ingeniería de requisitos ha sido objeto de creciente interés en los últimos años, especialmente con el avance de técnicas NLP y, más recientemente, de los LLMs. Diversos estudios han explorado el potencial de estos modelos para asistir en tareas tradicionalmente engorrosas en lenguaje natural (e.g., elicitación, análisis, reformulación y validación de requisitos). Investigaciones recientes muestran que los LLMs pueden mejorar la calidad de los artefactos de requisitos y facilitar la automatización parcial de diferentes actividades del proceso de ingeniería de requisitos, incluyendo la generación de historias de usuario, la clasificación de requisitos y la evaluación de su calidad textual [16, 17]. En particular, algunos trabajos han demostrado la viabilidad de utilizar LLMs para generar artefactos derivados de

requisitos o asistir en su análisis semántico dentro de flujos de trabajo de desarrollo de software [18, 19]. Estos avances sugieren que los modelos generativos pueden actuar como asistentes inteligentes en etapas tempranas del ciclo de vida del software, aunque su integración sistemática en procesos de ingeniería de requisitos aún se encuentra en una fase exploratoria.

Paralelamente, la generación de datos sintéticos mediante modelos generativos ha emergido como una estrategia prometedora para abordar la escasez de conjuntos de datos anotados en múltiples dominios. Los LLMs permiten producir grandes volúmenes de datos textuales controlados mediante prompts, lo que facilita la creación de datasets para entrenamiento, evaluación o ampliación de datos existentes. Estudios recientes han analizado el uso de LLMs para generar, curar y evaluar datos sintéticos, destacando su potencial para complementar o sustituir parcialmente conjuntos de datos reales cuando estos son limitados o costosos de obtener [20]. Aplicaciones de este enfoque se han observado en diversos contextos, incluyendo la generación automática de datasets en dominios especializados como análisis forense digital o sistemas legales basados en Inteligencia Artificial (AI, por sus siglas en inglés)[21, 22]. No obstante, la literatura también señala desafíos importantes relacionados con la calidad, coherencia y fiabilidad de los datos generados sintéticamente, lo que hace necesario desarrollar mecanismos sistemáticos de validación y control de calidad.

En este contexto, ha surgido recientemente el paradigma *LLM-as-a-Judge*, en el cual los modelos de lenguaje se utilizan no solo como generadores de contenido, sino también como evaluadores automáticos de las salidas producidas por otros modelos. Este enfoque ha sido adoptado en múltiples estudios de evaluación de modelos generativos, donde los LLMs actúan como evaluadores capaces de analizar criterios semánticos complejos que no pueden capturarse fácilmente mediante métricas automáticas tradicionales [23]. Investigaciones recientes han demostrado que este tipo de evaluación puede aproximar razonablemente los juicios humanos en tareas de generación de lenguaje natural, especialmente cuando se utilizan criterios explícitos o esquemas de comparación entre salidas [24]. Sin embargo, el uso de LLMs como evaluadores también plantea desafíos metodológicos, incluyendo posibles sesgos, dependencia de los prompts y riesgos de circularidad cuando los modelos se evalúan entre sí.

A pesar de estos avances, la literatura actual presenta todavía una brecha en la integración de estas tres líneas de investigación. En particular, existen pocos enfoques que combinen generación de datos sintéticos, ejecución local de modelos y mecanismos estructurados de evaluación automática dentro de un mismo framework orientado a artefactos de ingeniería de requisitos. LocalLLM-DataForge aborda esta brecha mediante un framework diseñado para integrar estos elementos en un entorno capaz de generar y evaluar descomposiciones de historias de usuario de forma sistemática.

3 Framework LocalLLM-DataForge

LocalLLM-DataForge es un framework diseñado para la generación, transformación y evaluación automática de artefactos de ingeniería de requisitos mediante modelos

de lenguaje ejecutados localmente. Su propósito principal es proporcionar una arquitectura modular, reproducible y extensible que permita integrar múltiples etapas de procesamiento dentro de un mismo flujo de trabajo.

A diferencia de enfoques tradicionales centrados en el entrenamiento de modelos, LocalLLM-DataForge se enfoca en la orquestación de modelos preentrenados para la producción controlada de salidas y su evaluación sistemática. De esta forma se facilita la experimentación reproducible en entornos sin dependencia de servicios en la nube.

3.1 Arquitectura General

El framework se estructura como un pipeline de procesamiento basado en DataFrames, donde cada componente representa una transformación explícita sobre los datos de entrada. Este enfoque permite modelar el flujo de trabajo como una secuencia de operaciones deterministas y trazables, en las que cada etapa produce nuevas representaciones sin alterar los datos originales. Como resultado, se favorece la auditabilidad del proceso, la inspección intermedia de resultados y la reproducibilidad experimental.

La elección de un modelo basado en DataFrames responde a la necesidad de manejar simultáneamente múltiples versiones de los artefactos generados. En particular, cada historia de usuario puede dar lugar a diversas descomposiciones producidas por distintos modelos o configuraciones, las cuales son almacenadas como columnas independientes dentro de la misma estructura. Esta organización permite realizar comparaciones sistemáticas sin requerir estructuras externas adicionales ni procesos de sincronización complejos.

El flujo general del pipeline sigue cinco etapas principales: (1) carga de datos, (2) generación de artefactos, (3) comparación y evaluación, (4) obtención de métricas, y (5) almacenamiento de resultados. Estas etapas no se implementan como bloques monolíticos, sino como componentes desacoplados que operan sobre el mismo DataFrame, lo que permite reorganizar, extender o reemplazar partes del pipeline sin afectar el resto del framework.

Un aspecto clave de la arquitectura es la separación explícita entre generación y evaluación. Mientras que los modelos generadores se encargan de producir descomposiciones a partir de historias de usuario, el componente evaluador opera de forma independiente para analizar la calidad de dichas salidas bajo criterios estructurados. Esta separación permite experimentar con configuraciones heterogéneas de modelos sin introducir sesgos en la evaluación, además de facilitar la incorporación de nuevos mecanismos de validación en futuras extensiones del framework.

La Figura 1 representa el comportamiento general del pipeline modelado mediante un diagrama de actividad UML, permitiendo representar explícitamente el flujo de procesamiento y la ejecución paralela de los modelos generadores. Este inicia con la carga del dataset de historias de usuario, seguido por una etapa de generación paralela en la que múltiples modelos producen descomposiciones independientes bajo configuraciones diferenciadas. Posteriormente, un componente evaluador basado en el paradigma *LLM-as-a-Judge* compara las salidas generadas y asigna las métricas calculadas. Finalmente, los resultados son integrados en el DataFrame de salida, permitiendo su análisis posterior de forma sistemática.




Fig. 1 Diagrama de actividad UML del framework LocalLLM-DataForge.

Este diseño arquitectónico prioriza la modularidad, la transparencia en el flujo de datos y la capacidad de experimentación controlada, aspectos fundamentales en estudios orientados a evaluar el comportamiento de modelos de lenguaje en tareas de ingeniería de requisitos.

3.2 Modelo de Ejecución del Pipeline

El núcleo operativo del framework es la clase `DataForgePipeline`, la cual implementa un modelo de ejecución basado en la composición secuencial de pasos modulares. En este enfoque, cada paso se define como una función de transformación que recibe un `DataFrame` de entrada y produce un nuevo `DataFrame` enriquecido, preservando las columnas originales y agregando nuevas representaciones derivadas. Este tipo de organización es consistente con modelos de procesamiento basados en dataflow, donde el cómputo se expresa como una secuencia de transformaciones sobre los datos [25].

Este modelo puede interpretarse como una forma de *dataflow pipeline*, donde el estado del sistema se materializa explícitamente en cada etapa mediante estructuras tabulares. A diferencia de arquitecturas imperativas tradicionales, en las que las transformaciones pueden sobrescribir información previa, el diseño adoptado en

LocalLLM-DataForge favorece la inmutabilidad lógica de los datos, permitiendo rastrear el origen y evolución de cada artefacto generado a lo largo del proceso.

Una característica distintiva del pipeline es su naturaleza declarativa. Los experimentos se definen especificando una secuencia ordenada de pasos y sus configuraciones, sin necesidad de gestionar explícitamente el flujo de control interno. Este enfoque contrasta con prácticas tradicionales basadas en scripts ad-hoc, las cuales dificultan la reproducibilidad y la reutilización de configuraciones experimentales. En este sentido, frameworks recientes para procesamiento de datos con LLMs han destacado la importancia de abstracciones modulares y pipelines configurables para mejorar la trazabilidad y reproducibilidad de los experimentos [26].

Desde una perspectiva de ingeniería, este modelo promueve un alto grado de desacoplamiento entre componentes. Cada paso encapsula su lógica de procesamiento y se comunica con el resto del pipeline exclusivamente a través del `DataFrame` compartido. Este tipo de diseño modular ha sido ampliamente adoptado en sistemas modernos de procesamiento de datos y aprendizaje automático, donde la composición de transformaciones reutilizables permite construir flujos de trabajo complejos de manera flexible [26].

Adicionalmente, el pipeline soporta la ejecución incremental y la inspección intermedia de resultados. Dado que cada transformación produce una nueva versión del `DataFrame`, es posible analizar el estado del sistema en cualquier punto del flujo, lo cual resulta particularmente útil en tareas de depuración, validación de prompts y análisis cualitativo de salidas generadas por modelos de lenguaje.

En conjunto, el modelo de pipeline adoptado en LocalLLM-DataForge proporciona una base estructurada para la orquestación de modelos LLMs en tareas de generación y evaluación. De esta forma se alinea con tendencias recientes en el diseño de sistemas LLMs multi-etapa que integran componentes generativos y evaluadores dentro de un mismo flujo de procesamiento [27].

3.3 Componentes del Pipeline

El framework incorpora un conjunto de componentes especializados que encapsulan funcionalidades específicas dentro del pipeline. Este diseño sigue principios de arquitecturas tipo *pipes-and-filters*, en las que el procesamiento se descompone en una secuencia de etapas independientes que transforman progresivamente los datos de entrada. En este tipo de arquitectura, cada componente, o filtro, realiza una operación específica y transmite su salida al siguiente componente a través de canales definidos [28]. Este enfoque ha sido ampliamente adoptado en sistemas de procesamiento de datos y pipelines de aprendizaje automático, donde la separación de responsabilidades permite construir flujos complejos a partir de transformaciones simples y desacopladas.

Dentro de este esquema, el componente `LoadDataFrame` actúa como punto de entrada del pipeline, encargándose de la ingesta de datos estructurados y su normalización en una representación tabular unificada. Su función es establecer un estado inicial consistente que permita aplicar transformaciones posteriores sin ambigüedad estructural. Por su parte, el componente `OllamaLLMStep` encapsula la interacción con modelos de lenguaje ejecutados localmente, permitiendo parametrizar su comportamiento mediante configuraciones explícitas como temperatura, tamaño de lote y

número máximo de tokens. Este componente materializa las salidas generadas por los modelos como nuevas columnas dentro del DataFrame, integrando de manera directa los artefactos generados en el flujo de procesamiento. La incorporación de modelos de lenguaje dentro de pipelines estructurados constituye una tendencia reciente en sistemas multi-etapa, donde múltiples modelos colaboran para resolver tareas complejas mediante generación y transformación progresiva de información [29].

El componente `ComparisonJudgeStep` implementa un mecanismo de evaluación basado en el paradigma *LLM-as-a-Judge*, en el cual un modelo de lenguaje es utilizado como evaluador de las salidas generadas por otros modelos. Este enfoque ha ganado relevancia como alternativa a métricas tradicionales en tareas abiertas, permitiendo aproximar juicios cualitativos mediante evaluaciones estructuradas y reproducibles [30]. En este contexto, el componente recibe múltiples candidatos generados y produce métricas de calidad que son integradas directamente en el DataFrame, lo que permite su análisis posterior sin requerir procesamiento adicional.

Estos componentes conforman una arquitectura en la que cada etapa del procesamiento se encuentra claramente definida y desacoplada, desde la generación hasta la evaluación. Esta separación de responsabilidades permite no solo extender el pipeline mediante la incorporación de nuevos módulos, sino también experimentar con distintas configuraciones de modelos y estrategias de evaluación sin introducir dependencias rígidas, alineándose con principios fundamentales de diseño en arquitecturas orientadas a procesamiento de datos.

3.4 Ejecución Local y Gestión de Recursos

Una característica central de LocalLLM-DataForge es su enfoque en la ejecución local de modelos de lenguaje, lo que permite mantener un control completo sobre los datos procesados y los recursos computacionales utilizados. A diferencia de los enfoques basados en servicios en la nube, donde las entradas y salidas pueden ser almacenadas o procesadas por terceros, la ejecución local garantiza que toda la información permanezca dentro del entorno del usuario, lo cual resulta particularmente relevante en contextos donde se manejan datos sensibles o sujetos a regulaciones de privacidad [31]. Este aspecto ha sido identificado en la literatura como una de las principales ventajas de los modelos de código abierto y despliegue local, ya que elimina riesgos asociados a la exposición de datos y mejora la transparencia del procesamiento [32].

Desde una perspectiva experimental, la ejecución local también contribuye significativamente a la reproducibilidad de los resultados. En entornos basados en APIs externas, factores como cambios en versiones de modelos, ajustes internos no documentados o variaciones en la infraestructura pueden afectar los resultados obtenidos. En contraste, el uso de modelos locales permite fijar versiones específicas, configuraciones y condiciones de ejecución, asegurando que los experimentos puedan ser replicados bajo las mismas condiciones [32]. Esta propiedad es especialmente importante en estudios orientados a evaluar el comportamiento de modelos de lenguaje, donde pequeñas variaciones en el entorno pueden impactar de manera significativa las salidas generadas.

No obstante, la ejecución local introduce también desafíos asociados a la gestión eficiente de recursos computacionales. Los modelos de lenguaje requieren cantidades

significativas de memoria y capacidad de procesamiento, lo que obliga a diseñar mecanismos que optimicen su uso en hardware limitado. En este contexto, el framework implementa un esquema de procesamiento por lotes configurable que permite controlar el número de instancias procesadas simultáneamente, evitando desbordamientos del contexto y reduciendo la presión sobre la memoria disponible. Este enfoque permite adaptar dinámicamente la ejecución del pipeline a las capacidades del framework, manteniendo un equilibrio entre rendimiento y estabilidad operativa.

Adicionalmente, se incorpora un sistema de caché opcional que permite reutilizar resultados previamente generados cuando las entradas y configuraciones no han cambiado. Esta estrategia resulta particularmente útil en escenarios de experimentación iterativa, donde múltiples ejecuciones con parámetros similares son comunes. La reutilización de resultados no solo reduce el tiempo de ejecución, sino que también contribuye a la consistencia de los experimentos al evitar variaciones innecesarias en las salidas generadas.

En conjunto, el enfoque de ejecución local adoptado en LocalLLM-DataForge no solo responde a consideraciones de privacidad y control de datos, sino que también constituye una decisión metodológica orientada a garantizar reproducibilidad, trazabilidad y estabilidad en el proceso experimental, aspectos fundamentales en la evaluación rigurosa de sistemas basados en modelos de lenguaje.

3.5 Diseño de Prompts

El diseño de prompts constituye un componente metodológico central dentro del framework, ya que define la forma en que los modelos de lenguaje interpretan las tareas y generan sus respuestas. En el contexto de los LLMs, el prompt puede entenderse como un mecanismo de programación implícita, mediante el cual es posible guiar el comportamiento del modelo sin necesidad de modificar sus parámetros internos [33]. Diversos estudios han demostrado que la calidad, estructura y claridad del prompt influyen directamente en la precisión, consistencia y utilidad de las salidas generadas, posicionando al prompt engineering como una disciplina clave en el aprovechamiento efectivo de estos modelos [34].

En LocalLLM-DataForge, los prompts se diseñan siguiendo un enfoque estructurado basado en esquemas de instrucción–entrada–respuesta, en el que se especifican explícitamente tanto las restricciones de contenido como el formato esperado de salida. Este tipo de estructuración ha sido identificado como una estrategia efectiva para mejorar la consistencia de los resultados y facilitar su procesamiento automático, especialmente en tareas que requieren generar datos estructurados [35]. En particular, la imposición de formatos rígidos permite reducir la ambigüedad en las salidas y habilita su integración directa en el pipeline sin necesidad de etapas adicionales de limpieza o normalización.

Dentro del framework se emplean dos prompts principales: (i) un *prompt generador de tareas*, encargado de descomponer historias de usuario en conjuntos estructurados de tareas, y (ii) un *prompt de evaluación bajo el enfoque LLM-as-a-Judge*, orientado a valorar la calidad de dichas descomposiciones conforme a criterios definidos.

El *prompt generador* sigue un esquema de instrucción–entrada–respuesta, en el cual se especifican explícitamente las restricciones de descomposición, tales como la no

superposición de tareas, la claridad en la redacción y la obligatoriedad de un formato estructurado basado en campos de resumen y descripción. Estas restricciones delimitan el espacio de salida del modelo, favoreciendo la generación de artefactos consistentes y comparables.

Por su parte, el *prompt de evaluación* instruye al modelo para comparar dos descomposiciones alternativas de una misma historia de usuario y emitir un juicio estructurado. La evaluación se realiza con base en los cinco criterios de calidad, y produce una salida en formato JSON que incluye puntuaciones numéricas y una decisión final sobre la mejor alternativa.

Ambos prompts son diseñados bajo principios homogéneos de estructuración y control, pero responden a objetivos funcionales distintos dentro del pipeline. Con el fin de garantizar la reproducibilidad del experimento y la transparencia metodológica, las versiones completas de estos prompts se presentan en el Apéndice A y el Apéndice B, respectivamente.

En las tareas de generación, el prompt generador está diseñado para producir descomposiciones de historias de usuario bajo restricciones específicas, tales como la no superposición de tareas, la claridad en la redacción y la inclusión de campos estructurados como resumen y descripción. Estas restricciones actúan como mecanismos de control que delimitan el espacio de salida del modelo, favoreciendo la producción de artefactos consistentes y comparables. Por otro lado, en las tareas de evaluación, el prompt basado en LLM-as-a-Judge define explícitamente criterios de calidad y reglas de decisión, instruyendo al modelo para emitir juicios estructurados en formatos como JSON. Este enfoque permite transformar evaluaciones cualitativas en representaciones cuantificables que pueden ser integradas directamente en el flujo de procesamiento.

Adicionalmente, el uso de prompts estandarizados entre diferentes modelos permite realizar comparaciones más justas y controladas, evitando sesgos derivados de ajustes específicos para cada modelo. La literatura reciente ha señalado que la consistencia en el diseño de prompts es un factor crítico para garantizar la validez de evaluaciones comparativas entre LLMs, ya que pequeñas variaciones en la formulación pueden impactar significativamente los resultados obtenidos [35]. En este sentido, el framework adopta un enfoque uniforme en la definición de prompts, asegurando que las diferencias observadas en las salidas se deban principalmente a las características de los modelos y no a variaciones en las instrucciones proporcionadas.

Es por esto que el diseño de prompts en LocalLLM-DataForge no se limita a una tarea de configuración, sino que constituye un elemento fundamental del proceso experimental, al actuar como interfaz de control entre el investigador y el modelo. Este enfoque permite ejercer un control fino sobre la generación y evaluación de artefactos, alineándose con tendencias recientes que conciben el prompt engineering como una capa de abstracción clave en sistemas basados en modelos de lenguaje.

4 Resultados

Esta sección presenta los resultados del estudio experimental realizado para evaluar el desempeño del *framework* propuesto en la generación automática de descomposiciones de historias de usuario. En primer lugar, se describe la configuración experimental

empleada, incluyendo el entorno de ejecución, los modelos utilizados y el esquema de evaluación. Posteriormente, se presentan los resultados agregados obtenidos en las distintas pruebas, seguidos de un análisis detallado por criterio que permite identificar patrones de comportamiento y diferencias entre modelos. Finalmente, se discuten los hallazgos más relevantes derivados del estudio.

4.1 Configuración experimental

El estudio experimental se realizó utilizando el framework *LocalLLM-DataForge*, con el objetivo de evaluar la generación automática de descomposiciones de historias de usuario mediante modelos de lenguaje ejecutados localmente.

El entorno consistió en un servidor Dell equipado con un procesador AMD EPYC 9124 a 3.0 GHz (16 núcleos, 32 hilos, 64 MB de caché), con 64 GB de memoria RAM DDR5-4800 (4 módulos de 16 GB) y una GPU NVIDIA Ampere A2 con 16 GB de memoria. El pipeline se ejecutó utilizando Python v3.13.7 y Ollama v0.21.2 como plataforma de orquestación para la ejecución local de los modelos. La GPU fue utilizada para acelerar la inferencia de los modelos, permitiendo reducir los tiempos de generación y evaluación durante las pruebas experimentales.

El conjunto de datos base fue Salony¹, del cual se seleccionaron 1,139 de 1,998 historias de usuario que cumplieran con la estructura canónica “*As a(n) [role], I want [feature] so that [benefit]*”. Cada historia fue procesada por dos modelos generadores (G1 y G2), configurados con diferentes valores de temperatura. En particular, G1 utilizó una temperatura de 0.3, favoreciendo salidas más deterministas, mientras que G2 se configuró con una temperatura de 0.7, promoviendo una mayor diversidad. Por su parte, el modelo evaluador operó con una temperatura de 0.2, con el fin de mantener consistencia en los juicios emitidos.

Las descomposiciones generadas fueron evaluadas mediante un modelo bajo el paradigma *LLM-as-a-Judge*, asignando puntuaciones en cinco criterios: coherencia, completitud, viabilidad, formato y granularidad [36].

La selección de estos criterios se fundamenta en los principios de calidad de requisitos establecidos por la norma ISO/IEC/IEEE 29148:2018 [39]. En este sentido, la coherencia evalúa la correspondencia semántica con la historia de usuario, la completitud el grado de cobertura de los requerimientos, la viabilidad la factibilidad técnica de las tareas, el formato la claridad y estructura de la salida, y la granularidad la adecuación del nivel de descomposición.

Cada criterio fue evaluado en una escala de 0 a 10, con una puntuación máxima de 50 puntos [40]. La puntuación total de cada instancia se obtuvo como la suma de los cinco criterios evaluados. A partir de estas puntuaciones, se estableció un umbral de aprobación de 35 puntos (70%), permitiendo clasificar cada instancia como válida o no válida [42].

Sobre el conjunto de instancias evaluadas, se calcularon métricas agregadas como la media y la desviación estándar de las puntuaciones totales. La tasa de aprobación se definió como el porcentaje de instancias cuya puntuación total supera el umbral establecido. Por su parte, la tasa de victoria se calculó en el contexto de comparaciones

¹Salony: User Story Dataset disponible en Hugging Face, https://huggingface.co/datasets/salony/User_story.

directas entre dos descomposiciones, representando el porcentaje de comparaciones en las que una descomposición es preferida sobre la otra según la puntuación total asignada por el modelo evaluador.

Para analizar el impacto de distintas configuraciones de modelos de lenguaje, se definieron cuatro configuraciones experimentales (C1, C2, C3 y C4), cada una compuesta por dos modelos generadores (G1 y G2) y un modelo evaluador bajo el paradigma *LLM-as-a-Judge*. Las configuraciones evaluadas, presentadas en la Tabla 1, incluyen modelos de distintas familias, tamaños y arquitecturas.

Table 1 Model configurations evaluated in experimental tests

Config.	Role	Model	Architecture	Size
C1	G1	Llama 3.1	Dense Transformer (decoder) with GQA	8B
	G2	Mistral	Transformer with Sliding Window Attention	7B
	Judge	Qwen 3	Hybrid Transformer with GQA & Reasoning Mode	14B
C2	G1	Qwen 3	Hybrid Transformer with GQA & Reasoning Mode	8B
	G2	Gemma 4 (E4B)	Efficient Transformer with PLE	4B
	Judge	Qwen 2.5	Dense Transformer with SwiGLU & GQA	14B
C3	G1	Gemma 3	Multimodal Transformer with QK Norm	12B
	G2	Mistral Nemo	Dense Transformer (decoder) with GQA	12B
	Judge	Qwen 3	Hybrid Transformer with GQA & Reasoning Mode	14B
C4	G1	Qwen 3	Hybrid Transformer with GQA & Reasoning Mode	14B
	G2	Phi-4	Dense Transformer (10T synthetic data tokens)	14B
	Judge	GPT-OSS	Sparse MoE (3.6B active) with Variable CoT	20B

En cada configuración, ambos generadores procesaron el mismo conjunto de historias de usuario, produciendo descomposiciones alternativas para cada instancia. Esto garantiza la consistencia en la entrada de los modelos y permite una comparación directa entre sus salidas. Posteriormente, el modelo evaluador analizó ambas descomposiciones y asignó puntuaciones en los cinco criterios de calidad, determinando un ganador en cada caso.

4.2 Resultados globales

Con el objetivo de identificar patrones consistentes en el comportamiento de los modelos evaluados, se realizó un análisis comparativo considerando de manera conjunta los resultados de las pruebas experimentales. Este enfoque permite observar tendencias globales en términos de desempeño, estabilidad y comportamiento relativo entre modelos.

La Tabla 2 presenta las métricas agregadas para cada prueba, incluyendo la puntuación promedio junto con su desviación estándar ($Mean \pm Std$), así como la tasa de aprobación (*Pass*) y la tasa de victoria en comparaciones directas (*Win*).

Table 2 Resultados agregados por prueba

Config.	Gen.	Mean $\pm$ Std	Pass (%)	Win (%)
C1	G1: Llama 3.1	35.71 $\pm$ 9.88	55.22	72.78
C1	G2: Mistral	35.95 $\pm$ 10.26	55.22	27.22
C2	G1: Qwen 3	39.45 $\pm$ 5.50	90.61	18.70
C2	G2: Gemma 4	42.00 $\pm$ 3.30	97.63	81.30
C3	G1: Gemma 3	47.23 $\pm$ 8.05	90.87	99.56
C3	G2: Mistral Nemo	37.35 $\pm$ 5.04	83.93	0.44
C4	G1: Qwen 3	37.60 $\pm$ 8.59	73.22	54.96
C4	G2: Phi 4	38.43 $\pm$ 7.96	75.33	45.04

Como se observa, el comportamiento de los modelos varía significativamente entre configuraciones. En C1, ambos generadores presentan puntuaciones promedio similares, aunque G1 obtiene una mayor tasa de victoria. En C2, G2 supera claramente a G1 tanto en puntuación promedio como en tasa de aprobación y victoria. En contraste, en C3 se observa una dominancia marcada de G1, con una diferencia sustancial en puntuación promedio y una tasa de victoria cercana al 100%.

En contraste con las configuraciones anteriores, C4 presenta un comportamiento más equilibrado entre ambos generadores, con diferencias mínimas tanto en puntuación promedio como en tasa de victoria. Este resultado sugiere un escenario de convergencia en el desempeño, donde ninguno de los modelos domina claramente sobre el otro.

Los resultados experimentales evidencian patrones diferenciados en el comportamiento de los modelos generadores a través de las distintas configuraciones evaluadas. Si bien en algunas configuraciones las puntuaciones promedio son cercanas, en otras se observan diferencias significativas tanto en desempeño como en tasa de victoria, lo que indica que el rendimiento de los modelos depende fuertemente de la configuración empleada.

Sin embargo, el análisis de la distribución de puntuaciones revela diferencias más claras en la estabilidad y variabilidad de los modelos. La Figura 2 muestra la distribución de puntuaciones totales para cada configuración y generador.

En configuraciones como C3, G1 no solo alcanza valores más altos, sino que también presenta una distribución más concentrada, lo que indica mayor consistencia en la calidad de las descomposiciones. Por el contrario, G2 muestra mayor dispersión en varias configuraciones, reflejando una variabilidad más alta en sus resultados.

Asimismo, se identifican diferencias en la mediana y en la concentración de valores. En configuraciones como C3, G1 alcanza puntuaciones más altas y consistentes, mientras que G2 presenta una mayor dispersión y valores más bajos en comparación. Este comportamiento sugiere que, aunque los promedios globales puedan ser similares, la calidad de las descomposiciones generadas por G1 es más consistente en ciertos escenarios.

4.3 Análisis por criterio

En la Tabla 3 se presentan las puntuaciones promedio por criterio para cada prueba.




Fig. 2 Distribución de puntuaciones totales por configuración, para generadores con temperatura baja (G1: $T=0.3$) y temperatura alta (G2: $T=0.7$).

El análisis desagregado por criterio permite identificar patrones más específicos en el comportamiento de los modelos. La Figura 3 presenta la comparación de los cinco criterios de evaluación para cada configuración y generador.

En el criterio de *coherencia*, ambos modelos presentan desempeños similares en todas las configuraciones, con diferencias mínimas. En C2, ambos alcanzan valores altos y prácticamente equivalentes, mientras que en C3 se observa una ligera ventaja de G1. En C4, esta tendencia se mantiene, con puntuaciones muy cercanas entre ambos modelos, lo que refuerza la estabilidad de este criterio frente a cambios en la configuración.

En *completitud*, se observa un comportamiento diferenciado. G2 supera a G1 en la configuración C2, alcanzando valores notablemente más altos. Sin embargo, en C3, G1 obtiene una puntuación considerablemente superior, lo que indica que el desempeño en este criterio depende fuertemente de la configuración del modelo. En C4, G2 recupera una ligera ventaja, aunque con diferencias menos pronunciadas, lo que sugiere un escenario más equilibrado entre ambos modelos.

En cuanto a la *viabilidad*, ambos modelos presentan resultados cercanos en C1 y C2, con una ligera ventaja de G2 en C2. No obstante, en C3, G1 muestra un mejor desempeño, alcanzando valores más altos y consistentes. En C4, G1 mantiene una

Table 3 Puntuación promedio por criterio en las pruebas

Config.	Gen.	Coherencia	Compleitud	Viabilidad	Formato	Granularidad
C1	G1: Llama 3.1	4.92	4.58	4.97	5.27	4.48
C1	G2: Mistral	4.79	4.88	4.94	5.27	4.57
C2	G1: Qwen 3	8.62	7.82	7.83	8.88	6.66
C2	G2: Gemma 4	8.72	9.33	8.16	8.96	7.06
C3	G1: Gemma 3	8.63	8.98	8.45	8.97	8.46
C3	G2: Mistral Nemo	7.19	6.13	7.27	7.58	6.21
C4	G1: Qwen 3	6.53	5.89	6.59	6.64	5.84
C4	G2: Phi 4	6.44	6.63	6.43	6.64	6.20

ventaja marginal, aunque las diferencias entre modelos son reducidas en comparación con configuraciones anteriores.

El criterio de *formato* muestra uno de los comportamientos más estables entre modelos. En C1 y C2, ambos generadores presentan valores prácticamente idénticos, lo que sugiere que el cumplimiento de estructuras formales es relativamente independiente del modelo. Sin embargo, en C3, G1 supera claramente a G2. En C4, ambos modelos alcanzan nuevamente valores idénticos, reforzando la consistencia de este criterio a través de distintas configuraciones.

Finalmente, en *granularidad*, se observan diferencias más marcadas. Aunque ambos modelos presentan valores similares en C1, en C2 G2 obtiene una ligera ventaja. No obstante, en C3, G1 supera significativamente a G2, alcanzando una mayor adecuación en el nivel de descomposición de las tareas. En C4, G2 vuelve a presentar una ligera ventaja, aunque en un contexto de menor separación entre modelos.

En conjunto, los resultados muestran que el desempeño de los modelos no es uniforme, sino altamente dependiente de la configuración evaluada. Mientras que G2 presenta ventajas en ciertas configuraciones específicas, G1 demuestra un comportamiento más robusto en escenarios de mayor complejidad. Estos resultados evidencian que la evaluación basada únicamente en métricas agregadas puede ocultar diferencias relevantes, siendo necesario complementar el análisis con evaluaciones desagregadas por criterio y análisis de distribución de puntuaciones.

Particularmente, G1 tiende a ofrecer un desempeño más consistente en configuraciones más complejas (como C3), destacando en criterios como coherencia, formato y granularidad. Por otro lado, G2 muestra ventajas puntuales en criterios como completitud en ciertas configuraciones (especialmente C2), aunque con una mayor variabilidad en los resultados.

En términos generales, se observa que G2 tiende a destacar en criterios relacionados con la cobertura de requisitos, como completitud, particularmente en configuraciones como C2. Por otro lado, G1 muestra un mejor desempeño en criterios asociados a la calidad estructural de las descomposiciones, como coherencia, formato y granularidad, especialmente en configuraciones más complejas como C3.




Fig. 3 Comparación de criterios por configuración y generador.

5 Discusión

Los resultados obtenidos permiten analizar no solo el desempeño de los modelos evaluados, sino también las implicaciones del uso de LLMs locales dentro de pipelines estructurados para la generación de artefactos en ingeniería de requisitos.

Este comportamiento es consistente con lo reportado en la literatura reciente sobre el uso de LLMs en ingeniería de requisitos. Estudios como [17] señalan que el desempeño de los modelos en tareas de procesamiento de lenguaje natural depende fuertemente de factores como el diseño del prompt, la configuración de generación y el contexto de uso. Asimismo, Norheim et al. [18] identifican la sensibilidad a la configuración como uno de los principales desafíos al aplicar LLMs en tareas de ingeniería

de requisitos, lo que coincide con las variaciones observadas entre las configuraciones C2 y C3 en este estudio.

En primer lugar, se observa que el desempeño de los modelos no es uniforme, sino altamente dependiente de la configuración experimental. Las diferencias marcadas entre configuraciones como C2 y C3 evidencian que factores como la combinación de modelos, su tamaño y su parametrización influyen de manera significativa en la calidad de las descomposiciones generadas. Este comportamiento sugiere que la selección de modelos dentro de un pipeline multi-etapa no puede abordarse de forma aislada, sino que debe considerarse como un problema de configuración conjunta, donde la interacción entre generadores y evaluadores juega un papel determinante.

En este contexto, la configuración C4 introduce un escenario particularmente relevante, donde ambos generadores presentan capacidades comparables en términos de tamaño del modelo. Bajo estas condiciones, las diferencias de desempeño se reducen considerablemente, lo que sugiere que parte de la variabilidad observada en otras configuraciones puede estar asociada no solo a parámetros como la temperatura, sino también a diferencias en capacidad y arquitectura entre modelos.

Este resultado indica que, cuando se controlan factores como el tamaño del modelo, los sistemas tienden a converger en su desempeño, desplazando las diferencias hacia aspectos más finos como el estilo de generación o la priorización de ciertos criterios de calidad.

Un hallazgo relevante es la diferencia sistemática entre los generadores G1 y G2 en términos de estabilidad y variabilidad. Este fenómeno también ha sido reportado en estudios previos. En particular, Niv [16] destaca que, aunque los LLMs pueden alcanzar altos niveles de desempeño promedio, su comportamiento puede presentar variaciones significativas entre ejecuciones, lo que impacta la reproducibilidad de los resultados. Mientras que G2 muestra en algunos casos puntuaciones promedio más altas (e.g., C2), sus resultados presentan mayor dispersión, lo que indica una menor consistencia en la calidad de las salidas. En contraste, G1 tiende a generar descomposiciones más estables, especialmente en configuraciones más complejas como C3.

Este comportamiento puede explicarse, en parte, por la diferencia en la temperatura utilizada durante la generación. Estudios han demostrado que la temperatura tiene un impacto directo en la estabilidad de las salidas. Donde valores más bajos tienden a favorecer salidas más deterministas y mejorar la consistencia, mientras que valores más altos introducen mayor diversidad e incrementan la variabilidad [43]. Además, se ha observado que esta relación no es trivial y depende del tipo de tarea y del modelo utilizado, lo que refuerza la necesidad de ajustar cuidadosamente este parámetro en pipelines de generación y evaluación.

Desde la perspectiva de los criterios de evaluación, los resultados sugieren una separación clara entre dimensiones estructurales y semánticas de la calidad. Criterios como *formato* y *coherencia* presentan comportamientos relativamente estables entre modelos, lo que indica que los LLMs son capaces de adaptarse de manera consistente a restricciones estructuradas cuando estas se especifican explícitamente en los prompts. Por otro lado, criterios como *completitud* y *granularidad* muestran mayor variabilidad, lo que refleja la dificultad inherente de capturar aspectos más abstractos del proceso de descomposición de tareas.

Este comportamiento es consistente con tendencias reportadas en la literatura reciente. En particular, Ferrari y Spoletini [19] señalan que, aunque los LLMs muestran un desempeño sólido en tareas con restricciones formales o estructurales, aún presentan limitaciones en aspectos relacionados con la comprensión semántica profunda, como la adecuación del contenido y la cobertura de requisitos. Estas limitaciones están asociadas a preocupaciones sobre la corrección y confiabilidad de los artefactos generados por LLMs en ingeniería de requisitos, lo que explica la mayor estabilidad observada en criterios como formato y coherencia, en contraste con la variabilidad en completitud y granularidad.

En particular, la completitud emerge como uno de los criterios más sensibles a la configuración del modelo. Mientras que G2 obtiene mejores resultados en este aspecto en configuraciones como C2, su desempeño disminuye significativamente en escenarios más complejos como C3. Esto sugiere que la cobertura de requisitos no depende únicamente de la capacidad generativa del modelo, sino también de su habilidad para mantener consistencia semántica a medida que aumenta la complejidad de la descomposición.

Por otro lado, la granularidad muestra ser un criterio clave para diferenciar el desempeño de los modelos. Las diferencias observadas en C3 indican que algunos modelos son más capaces de encontrar un equilibrio adecuado en el nivel de detalle de las tareas, evitando tanto la sobre-descomposición como la generación de tareas demasiado generales. Este aspecto es particularmente relevante en contextos de planificación ágil, donde la calidad de la descomposición impacta directamente en la estimación y ejecución del trabajo.

Otro resultado significativo es la efectividad del enfoque comparativo basado en *LLM-as-a-Judge*. La utilización de un modelo evaluador para seleccionar entre múltiples descomposiciones permite identificar diferencias que no son evidentes únicamente a partir de métricas agregadas. En este sentido, la tasa de victoria proporciona una medida complementaria que captura la preferencia relativa entre alternativas, aportando una visión más rica del desempeño de los modelos.

Este enfoque se encuentra alineado con una línea creciente de investigación que propone el uso de modelos como evaluadores automáticos. Estudios recientes han demostrado que estos sistemas pueden alcanzar niveles comparables con evaluadores humanos en diversas tareas [24]. Sin embargo, también se han identificado limitaciones importantes, como la presencia de sesgos y la variabilidad en las puntuaciones asignadas. En particular, se ha señalado que estos sistemas pueden mostrar una tendencia a favorecer ciertos estilos de generación o estructuras de respuesta dependiendo del modelo evaluador y de su configuración. Esta observación resulta consistente con los resultados obtenidos en este estudio, donde las diferencias entre configuraciones evidencian que parámetros como la temperatura pueden influir no solo en la generación, sino también en la estabilidad de la evaluación automática.

En este contexto, enfoques como el propuesto por Do et al. [23] sugieren la incorporación de procesos iterativos y validación humana para mejorar la fiabilidad de los sistemas de evaluación automática, lo que representa una posible línea de mejora para el presente trabajo.

En relación con la generación de datos sintéticos, los resultados obtenidos son consistentes con trabajos como Li et al. [20], donde se señala que los LLMs pueden generar datos de alta calidad para tareas de procesamiento de lenguaje natural, aunque con limitaciones en términos de consistencia y cobertura. De manera similar, Ma et al. [22] y Chakir y Lahsen-Cherif [21] muestran que el uso de datos sintéticos puede mejorar el desempeño de modelos en dominios específicos, pero requiere mecanismos de validación robustos para garantizar su calidad. Estos hallazgos se reflejan en los resultados de este estudio, donde la calidad de las descomposiciones generadas depende significativamente de la configuración del modelo y del proceso de evaluación aplicado.

En términos de implicaciones, los resultados sugieren que el uso de LLMs locales constituye una alternativa prometedora para la generación de datasets sintéticos en ingeniería de requisitos, siempre que se integren mecanismos de validación estructurados dentro del pipeline. En particular, la combinación de generación controlada y evaluación automática permite mitigar la variabilidad inherente de los modelos y mejorar la consistencia de los artefactos generados. No obstante, los resultados también indican que la calidad alcanzada depende fuertemente de la configuración empleada, por lo que estos enfoques deben considerarse como herramientas de apoyo al proceso, más que como sustitutos directos de la validación humana.

No obstante, este estudio presenta ciertas limitaciones que deben ser consideradas. En relación con la validez interna, el uso de un LLM como evaluador plantea la cuestión de si las métricas obtenidas reflejan realmente la calidad de las descomposiciones o si están influenciadas por las características del modelo evaluador y su prompt. Aunque se emplearon criterios explícitos y una configuración conservadora de temperatura, no puede descartarse la presencia de sesgos sistemáticos en la evaluación.

En cuanto a la validez de constructo, si bien los cinco criterios utilizados (coherencia, completitud, viabilidad, formato y granularidad) se fundamentan en principios establecidos en la literatura de ingeniería de requisitos, es posible que no capturen completamente todas las dimensiones relevantes de la calidad en la descomposición de historias de usuario. Aspectos como la trazabilidad, la dependencia entre tareas o la alineación con objetivos de negocio no fueron considerados explícitamente en esta evaluación.

Respecto a la validez externa, los experimentos se realizaron sobre un único conjunto de datos (Salony), lo que limita la generalización de los resultados a otros dominios o tipos de requisitos. Las historias de usuario utilizadas presentan una estructura relativamente homogénea, lo que podría favorecer el desempeño de los modelos en comparación con escenarios más heterogéneos o menos estructurados.

Finalmente, estos resultados abren varias líneas de trabajo futuro. Entre ellas, se encuentra la incorporación de evaluadores híbridos que combinen métricas automáticas con validación humana, la exploración de estrategias de consenso entre múltiples jueces, y la extensión del framework a otros tipos de artefactos de requisitos. Asimismo, sería relevante analizar el impacto de técnicas más avanzadas de prompting y ajuste fino en la calidad de las descomposiciones generadas.

6 Conclusión

Este trabajo presentó *LocalLLM-DataForge*, un framework modular orientado a la generación y evaluación automática de descomposiciones de historias de usuario mediante modelos de lenguaje ejecutados localmente. La propuesta aborda dos problemáticas relevantes en la ingeniería de requisitos: la escasez de datasets anotados y la dependencia de servicios en la nube para el uso de LLMs. A través de una arquitectura basada en pipelines sobre DataFrames, el framework permite orquestar de manera reproducible procesos de generación, comparación y validación de artefactos, integrando modelos generadores y evaluadores dentro de un mismo flujo de trabajo.

Los resultados experimentales evidencian que es posible generar descomposiciones de tareas con niveles consistentes de calidad utilizando modelos de código abierto ejecutados localmente. Asimismo, se observó que el desempeño de los modelos depende significativamente de la configuración empleada, particularmente de la combinación de modelos y de parámetros como la temperatura. No obstante, también se identificaron escenarios donde las diferencias entre modelos se reducen considerablemente, evidenciando un comportamiento de convergencia cuando se utilizan modelos con capacidades similares. Este resultado sugiere que parte de la variabilidad observada no solo depende de parámetros de generación, sino también de factores como el tamaño y la arquitectura del modelo. En este contexto, el uso de estrategias de evaluación basadas en *LLM-as-a-Judge* demostró ser útil para comparar salidas alternativas y capturar diferencias que no son evidentes mediante métricas agregadas.

El análisis por criterio permitió identificar que los modelos tienden a comportarse de manera más estable en dimensiones estructurales como formato y coherencia, mientras que presentan mayor variabilidad en aspectos semánticos como completitud y granularidad. Este comportamiento se mantiene incluso en escenarios donde el desempeño global entre modelos es similar, lo que sugiere que las diferencias se desplazan hacia dimensiones específicas de calidad más que al rendimiento global.

En conjunto, este trabajo demuestra que los LLMs locales pueden constituir una alternativa viable para apoyar la generación de datasets sintéticos en investigación sobre ingeniería de requisitos, ofreciendo ventajas en términos de control de datos, reproducibilidad y costo. Además, el enfoque propuesto contribuye a la integración de generación y validación automática dentro de pipelines experimentales estructurados.

En relación con las contribuciones planteadas al inicio, este trabajo cumple dos aportaciones principales. En primer lugar, se presentó un framework completamente local, extensible y reproducible para la generación de datasets sintéticos a partir de historias de usuario. Este se basa en pipelines experimentales que permiten la orquestación controlada de procesos de generación y evaluación, reduciendo la dependencia de servicios en la nube. En segundo lugar, se definieron y operacionalizaron estrategias automáticas de validación basadas en *LLM-as-a-Judge*. Estas demostraron ser efectivas para comparar descomposiciones y capturar diferencias no evidentes mediante métricas agregadas, aunque sujetas a variabilidad dependiendo de la configuración del modelo.

Como trabajo futuro, se plantea extender el framework en varias direcciones. En primer lugar, se propone incorporar esquemas de evaluación híbridos que combinen juicios automáticos con validación humana, con el fin de mejorar la fiabilidad de las

métricas. En segundo lugar, se considera la exploración de estrategias de consenso entre múltiples modelos evaluadores para reducir posibles sesgos. Asimismo, sería relevante ampliar el conjunto de datos utilizado, incluyendo dominios más diversos y menos estructurados, con el objetivo de analizar la generalización del enfoque. Finalmente, se plantea la extensión del framework hacia otros artefactos de ingeniería de requisitos, como casos de uso, criterios de aceptación o especificaciones funcionales, así como la integración de técnicas avanzadas de prompting y ajuste fino para mejorar la calidad de las salidas generadas.

Appendix A Prompt de Generación de Tareas

Listing 1 Prompt generador de tareas

Below is an instruction that describes a task, paired with an input that provides a user story.

Write a response that appropriately completes the request.

Instruction:

Break this user story into smaller development tasks to help the developers implement it efficiently. You can divide this user story into as many tasks as needed, depending on its complexity. Each task must be unique, actionable, and non-overlapping.

Use the following format for the response:

```
1. summary: <task summary 1>
description: <task description 1>
2. summary: <task summary 2>
description: <task description 2>
```

```
N. summary: <task summary N>
description: <task description N>
```

Input:

```
{user_story}
```

Response:

Appendix B Prompt de Evaluación LLM-as-a-Judge

Listing 2 Prompt LLM-as-a-Judge

You are an expert software development manager evaluating two different breakdowns of a user story into development tasks.

Your job is to compare both breakdowns and determine which one is better overall.

USER STORY:
{user_story}

BREAKDOWN A:
{tasks_a}

BREAKDOWN B:
{tasks_b}

Evaluate both breakdowns based on these criteria (0-10 points each), aligned with ISO/IEC/IEEE 29148:2018 quality standards:

1. COHERENCE: Semantic correspondence between the generated tasks and the original user story. Does it maintain consistency with the user story intent? (0-10)
2. COMPLETENESS: Degree of coverage of implicit and explicit requirements. Does it cover all necessary aspects of the user story? (0-10)
3. FEASIBILITY: Technical feasibility of the proposed tasks. Are the tasks realistically implementable? (0-10)
4. FORMAT: Structure and clarity of the output. Is the response well-formatted, unambiguous, and easy to understand? (0-10)
5. GRANULARITY: Appropriateness of the decomposition level. Are tasks properly sized (not too big, not too small) and atomic? (0-10)

Respond in this exact JSON format:

```
{
  "breakdown_a": {
    "coherence": [score_0_to_10],
    "completeness": [score_0_to_10],
    "feasibility": [score_0_to_10],
    "format": [score_0_to_10],
    "granularity": [score_0_to_10],
    "total_score": [sum_of_all_scores],
    "strengths": "[brief_description_of_strengths]",
    "weaknesses": "[brief_description_of_weaknesses]"
  },
  "breakdown_b": {
    "coherence": [score_0_to_10],
    "completeness": [score_0_to_10],
    "feasibility": [score_0_to_10],
    "format": [score_0_to_10],
    "granularity": [score_0_to_10],
    "total_score": [sum_of_all_scores],
    "strengths": "[brief_description_of_strengths]",
```

```

    "weaknesses": "[brief_description_of_weaknesses]"
  },
  "winner": "[A_or_B]",
  "reason": "[brief_explanation_of_why_the_winner_is_better]"
}

```

References

- [1] Cohn, M.: User Stories Applied: For Agile Software Development. Addison Wesley Longman Publishing Co., Inc., USA (2004)
- [2] Beck, K.: Extreme Programming Explained: Embrace Change. Addison-Wesley Longman Publishing Co., Inc., USA (1999)
- [3] Rubin, K.S.: Essential Scrum: A Practical Guide to the Most Popular Agile Process, 1st edn. Addison-Wesley Professional, Boston, MA (2012)
- [4] Schwaber, K., Sutherland, J.: The Scrum Guide: The Definitive Guide to Scrum: The Rules of the Game. Scrum.org & Scrum Inc. (2020). <https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-US.pdf>
- [5] Lucassen, G., Dalpiaz, F., Van Der Werf, J.M., Brinkkemper, S.: Improving agile requirements: the quality user story framework and tool. *Requir. Eng.* **21**(3), 383–403 (2016) <https://doi.org/10.1007/s00766-016-0250-x>
- [6] Gorschek, T., Garre, P., Larsson, S., Wohlin, C.: A model for technology transfer in practice. *IEEE Softw.* **23**(6), 88–95 (2006) <https://doi.org/10.1109/MS.2006.147>
- [7] Chen, M., Tworek, J., Jun, H., Yuan, Q., Pondé, H., Kaplan, J., Edwards, H., Burda, Y., Joseph, N., Brockman, G., Ray, A., Puri, R., Krueger, G., Petrov, M., Khlaaf, H., Sastry, G., Mishkin, P., Chan, B., Gray, S., Ryder, N., Pavlov, M., Power, A., Kaiser, L., Bavarian, M., Winter, C., Tillet, P., Such, F.P., Cummings, D.W., Plappert, M., Chantzis, F., Barnes, E., Herbert-Voss, A., Guss, W.H., Nichol, A., Babuschkin, I., Balaji, S., Jain, S., Carr, A., Leike, J., Achiam, J., Misra, V., Morikawa, E., Radford, A., Knight, M.M., Brundage, M., Murati, M., Mayer, K., Welinder, P., McGrew, B., Amodei, D., McCandlish, S., Sutskever, I., Zaremba, W.: Evaluating large language models trained on code. *ArXiv abs/2107.03374* (2021)
- [8] White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith, J., Schmidt, D.C.: A prompt pattern catalog to enhance prompt engineering with chatgpt. In: *Proceedings of the 30th Conference on Pattern Languages of Programs. PLoP '23*. The Hillside Group, USA (2023)
- [9] Zhao, L., Alhoshan, W., Ferrari, A., Letsholo, K.J., Ajagbe, M.A., Chioasca,

- E.-V., Batista-Navarro, R.T.: Natural language processing for requirements engineering: A systematic mapping study. *ACM Comput. Surv.* **54**(3) (2021) <https://doi.org/10.1145/3444689>
- [10] Zadenoori, M.A., Dabrowski, J., Alhoshan, W., Zhao, L., Ferrari, A.: Large language models (llms) for requirements engineering (re): A systematic literature review. *ArXiv abs/2509.11446* (2025)
 - [11] Alhaizaey, A., Al-Mashari, M.: An aggregated dataset of agile user stories and use case taxonomy for ai-driven research. *International Journal of Advanced Computer Science and Applications* **16**(9) (2025) <https://doi.org/10.14569/IJACSA.2025.0160925>
 - [12] Nadăș, M., Diosan, L., Tomescu, A.: Synthetic data generation using large language models: Advances in text and code. *IEEE Access* **PP**, 1–1 (2025) <https://doi.org/10.1109/ACCESS.2025.3589503>
 - [13] Ho, N., Schmid, L., Yun, S.-Y.: Large language models are reasoning teachers. In: *Annual Meeting of the Association for Computational Linguistics* (2022). <https://api.semanticscholar.org/CorpusID:254877399>
 - [14] Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E.H., Zhou, D.: Self-consistency improves chain of thought reasoning in language models. *ArXiv abs/2203.11171* (2022)
 - [15] Li, Y., Lin, Z., Zhang, S.D., Fu, Q., Chen, B., Lou, J.-G., Chen, W.: Making language models better reasoners with step-aware verifier. In: *Annual Meeting of the Association for Computational Linguistics* (2022). <https://api.semanticscholar.org/CorpusID:259370847>
 - [16] Niv, S.: Leveraging the performance of large language models in systems engineering applications. *Journal of Information Systems Engineering and Management* **10**, 677–687 (2025) <https://doi.org/10.52783/jisem.v10i27s.4524>
 - [17] Vogelsang, A., Fischbach, J.: In: Ferrari, A., Ginde, G. (eds.) *Using Large Language Models for Natural Language Processing Tasks in Requirements Engineering: A Systematic Guideline*, pp. 435–456. Springer, Cham (2025). https://doi.org/10.1007/978-3-031-73143-3_16 . https://doi.org/10.1007/978-3-031-73143-3_16
 - [18] Norheim, J.J., Rebentisch, E., Xiao, D., Draeger, L., Kerbrat, A., Weck, O.L.: Challenges in applying large language models to requirements engineering tasks. *Design Science* **10**, 16 (2024) <https://doi.org/10.1017/dsj.2024.8>
 - [19] Ferrari, A., Spoletini, P.: Formal requirements engineering and large language models: A two-way roadmap. *Inf. Softw. Technol.* **181**(C) (2025) <https://doi.org/10.1016/j.infsof.2025.107697>

- [20] Li, Z., Zhu, H., Lu, Z., Yin, M.: Synthetic Data Generation with Large Language Models for Text Classification: Potential and Limitations. <https://doi.org/10.18653/v1/2023.emnlp-main.647> . <https://aclanthology.org/2023.emnlp-main.647/>
- [21] Chakir, Y., Lahsen-Cherif, I.: Forensicsdata: A digital forensics dataset for large language models. In: 2025 21th International Conference on Wireless and Mobile Computing, Networking and Communications (WiMob), pp. 1–6 (2025). <https://doi.org/10.1109/WiMob66857.2025.11257556>
- [22] Ma, H., Lu, Y., Xiao, Z., Feng, J., Zhang, H., Yu, J.: Sdd-lawllm: Advancing intelligent legal systems through synthetic data-driven fine-tuning of large language models. *Electronics* **14**(4) (2025) <https://doi.org/10.3390/electronics14040742>
- [23] Do, H.J., Ashktorab, Z., Gajcin, J., Miehl, E., Cooper, M.S., Pan, Q., Daly, E.M., Geyer, W.: Generate, evaluate, iterate: Synthetic data for human-in-the-loop refinement of llm judges. *ArXiv* **abs/2511.04478** (2025)
- [24] Chirkova, N., Ajayi, T.O., Aycok, S., Mujahid, Z.M., Perlić, V., Borisova, E., Vartampetian, M.: LLM-as-a-qualitative-judge: automating error analysis in natural language generation. In: Chen, P., Zouhar, V., Hu, H., Khanuja, S., Zhu, W., Haddow, B., Birch, A., Aji, A.F., Sennrich, R., Hooker, S. (eds.) *Proceedings of the First Workshop on Multilingual Multicultural Evaluation*, pp. 99–132. Association for Computational Linguistics, Rabat, Morocco (2026). <https://doi.org/10.18653/v1/2026.mme-main.7> . <https://aclanthology.org/2026.mme-main.7/>
- [25] Lienhardt, M., ter Beek, M.H., Damiani, F.: Product lines of dataflows. *Journal of Systems and Software* **210**, 111928 (2024) <https://doi.org/10.1016/j.jss.2023.111928>
- [26] Liang, H., Ma, X., Liu, Z., Wong, Z.H., Zhao, Z., Meng, Z., He, R., Shen, C., Cai, Q., Han, Z., Qiang, M., Feng, Y., Bai, T., Pan, Z., Guo, Z., Jiang, Y., Deng, J., You, Q., Lai, P., Guo, T., Tsai, C.H., Feng, H., Hu, R., Yu, W.-t., Niu, J., Zeng, B., An, R., Ma, L., Huang, J., Zheng, Y., He, C., Tang, L., Cui, B., Weinan, E., Zhang, W.: Dataflow: An llm-driven framework for unified data preparation and workflow automation in the era of data-centric ai. *ArXiv* **abs/2512.16676** (2025)
- [27] Zhu, C., Hong, S., Wu, J., Chawla, K., Tang, C., Yin, Y., Wolfe, N., Babinsky, E., Liu, D.: Raffles: Reasoning-based attribution of faults for llm systems. In: *Conference of the European Chapter of the Association for Computational Linguistics* (2025). <https://api.semanticscholar.org/CorpusID:281204051>
- [28] Warnett, S.J., Ntontos, E., Zdun, U.: Mlops pipeline generation for reinforcement learning: A low-code approach using large language models. *Journal of Systems and Software* **235**, 112760 (2026) <https://doi.org/10.1016/j.jss.2025.112760>

- [29] Schnabel, J.A., Trippas, J.R., Scholer, F., Hettiachchi, D.: Multi-stage large language model pipelines can outperform gpt-4o in relevance assessment. Companion Proceedings of the ACM on Web Conference 2025 (2025)
- [30] Gu, J., Jiang, X., Shi, Z., Tan, H., Zhai, X., Xu, C., Li, W., Shen, Y., Ma, S., Liu, H., Wang, Y., Guo, J.: A survey on llm-as-a-judge. ArXiv **abs/2411.15594** (2024)
- [31] Kivimäki, T.: Usability evaluation of the local large language models. Master’s thesis, University of Turku, Turku, Finland (June 2025). <https://www.utupub.fi/handle/11111/20392>
- [32] Carammia, M., Iacus, S.M., Porro, G.: Rethinking scale: The efficacy of fine-tuned open-source llms in large-scale reproducible social science research. ArXiv **abs/2411.00890** (2024)
- [33] Vatsal, S., Dubey, H.: A survey of prompt engineering methods in large language models for different nlp tasks. ArXiv **abs/2407.12994** (2024)
- [34] Chen, B., Zhang, Z., Langrené, N., Zhu, S.: Unleashing the potential of prompt engineering for large language models. Patterns **6**(6), 101260 (2025) <https://doi.org/10.1016/j.patter.2025.101260>
- [35] White, J., Elnashar, A., Schmidt, D.: Prompt engineering for structured data a comparative evaluation of styles and llm performance. Preprints (2025) <https://doi.org/10.20944/preprints202506.1937.v1>
- [36] Baysan, M.S., Uysal, S., İşlek, , Çığ Karaman, , Güngör, T.: Llm-as-a-judge: automated evaluation of search query parsing using large language models. Frontiers in Big Data **Volume 8 - 2025** (2025) <https://doi.org/10.3389/fdata.2025.1611389>
- [37] PPCexpo Editorial Team: 10 Point Likert Scale: Everything You Need to Know. Accessed: 2026-04-26 (2024). <https://ppcexpo.com/blog/10-point-likert-scale>
- [38] Preston, C.C., Colman, A.M.: Optimal number of response categories in rating scales: reliability, validity, discriminating power, and respondent preferences. Acta Psychologica **104**(1), 1–15 (2000) [https://doi.org/10.1016/S0001-6918\(99\)00050-5](https://doi.org/10.1016/S0001-6918(99)00050-5)
- [39] Systems and Software Engineering — Life Cycle Processes — Requirements Engineering. International Organization for Standardization. <https://www.iso.org/standard/72089.html>
- [40] Wu, H., Leung, S.-O.: Can likert scales be treated as interval scales? Journal of Social Service Research **43**(4), 527–532 (2017) <https://doi.org/10.1080/01488376.2017.1329775>

- [41] Dawes, J.: Do data characteristics change according to the number of scale points used? *Int. J. Mark. Res.* **50**, 61–77 (2007)
- [42] Consumer Council for Water: Research into threshold of acceptability. Technical report, Consumer Council for Water (CCW) (August 2013). Accessed: 2026-04-26. <https://www.ccw.org.uk/publication/research-into-threshold-of-acceptability/>
- [43] Li, L., Sleem, L., Xu, Y., Song, Y., Jia, A., François, J., State, R.: The Necessity of Setting Temperature in LLM-as-a-Judge (2026). <https://doi.org/10.48550/arXiv.2603.28304>